Språkmodeller för utvecklare

Språkmodeller för utvecklare

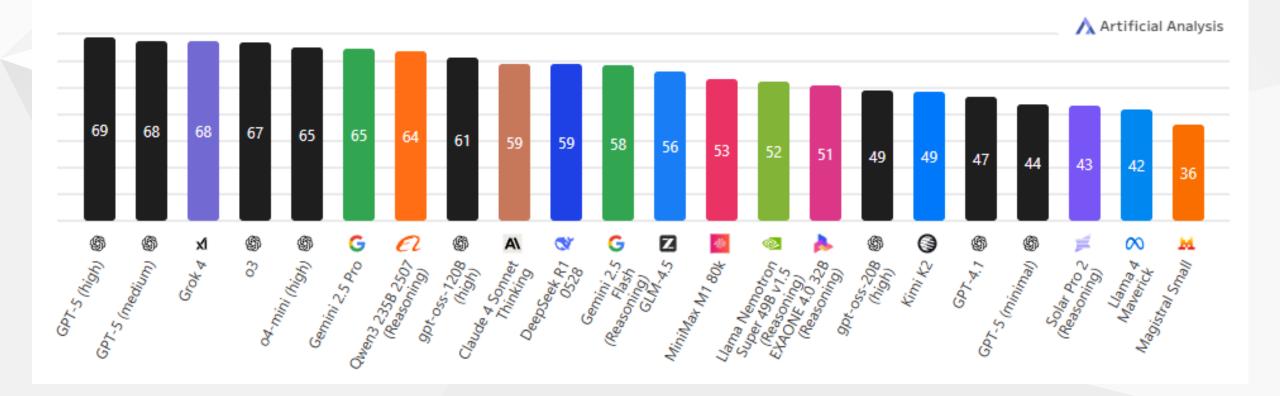
• **Syfte**: Förstå skillnader mellan olika språkmodeller och när man ska välja vilken typ av modell.

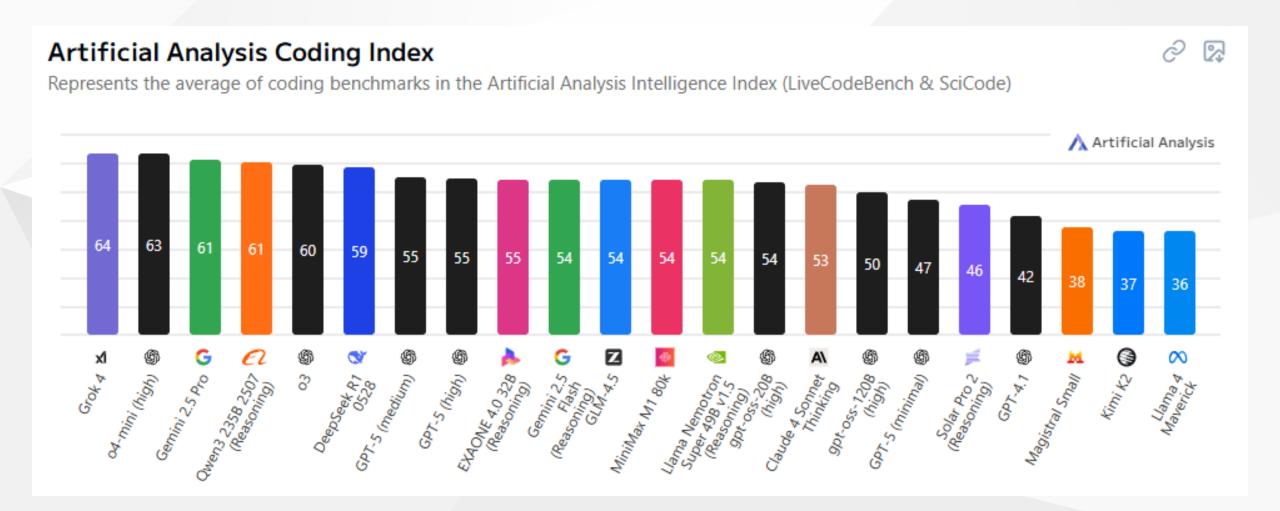
Artificial Analysis Intelligence Index





Artificial Analysis Intelligence Index v2.2 incorporates 8 evaluations: MMLU-Pro, GPQA Diamond, Humanity's Last Exam, LiveCodeBench, SciCode, AIME, IFBench, AA-LCR





Att välja modell

- Benchmarks säger någonting, men långt ifrån allt.
- Det finns ingen modell som är bäst på allt.
- Svarskvalitet är inte det enda att ta hänsyn till, även hastighet och kostnad spelar roll.

Andra faktorer

- Context window: hur många tokens (1 token ≈ 3-5 tecken)
 modellen kan hantera samtidigt.
- Säkerhet: var skickas din data?
- Function/tool calling: behöver du att modellen klarar av att använda externa verktyg?

Tool calling

• Vad är tool calling? Modellen anropar definierade verktyg med strukturerade argument för att t.ex. söka/läsa/skriva filer, köra kommandon eller skicka ett meddelande i Slack.

Stor skillnad mellan modeller.

Vad är en reasoning-modell?

- Många av de nya modellerna idag är reasoning-modeller.
- Är tränade på att bryta ned problem i mindre delar och tänka stegvis.
- Resonerandet blir en del av modellens svar.
- Starkare på oklara, flerstegs- och öppna problem.
- Långsammare och dyrare.

När ska man inte välja en reasoning-modell?

- Snabba ändringar nära markören: små kodfixar, kommentarer, enklare frågor.
- Kostnadskänsliga uppgifter: summeringar, översättningar, extrahering, loggsökningar.

Sammanfattning

- Välj rätt modell för jobbet: Ingen modell är bäst på allt. Valet beror på uppgiften kodning, analys, snabba ändringar, etc.
- Benchmarks ofta opålitliga: Titta på relevanta tester för ditt användningsområde, testa och få en känsla för nya modeller.
- Balansera kvalitet, hastighet och kostnad: En "smartare" modell är ofta långsammare och dyrare. Använd dem för komplexa problem. För enklare uppgifter räcker ofta en snabbare och billigare modell.